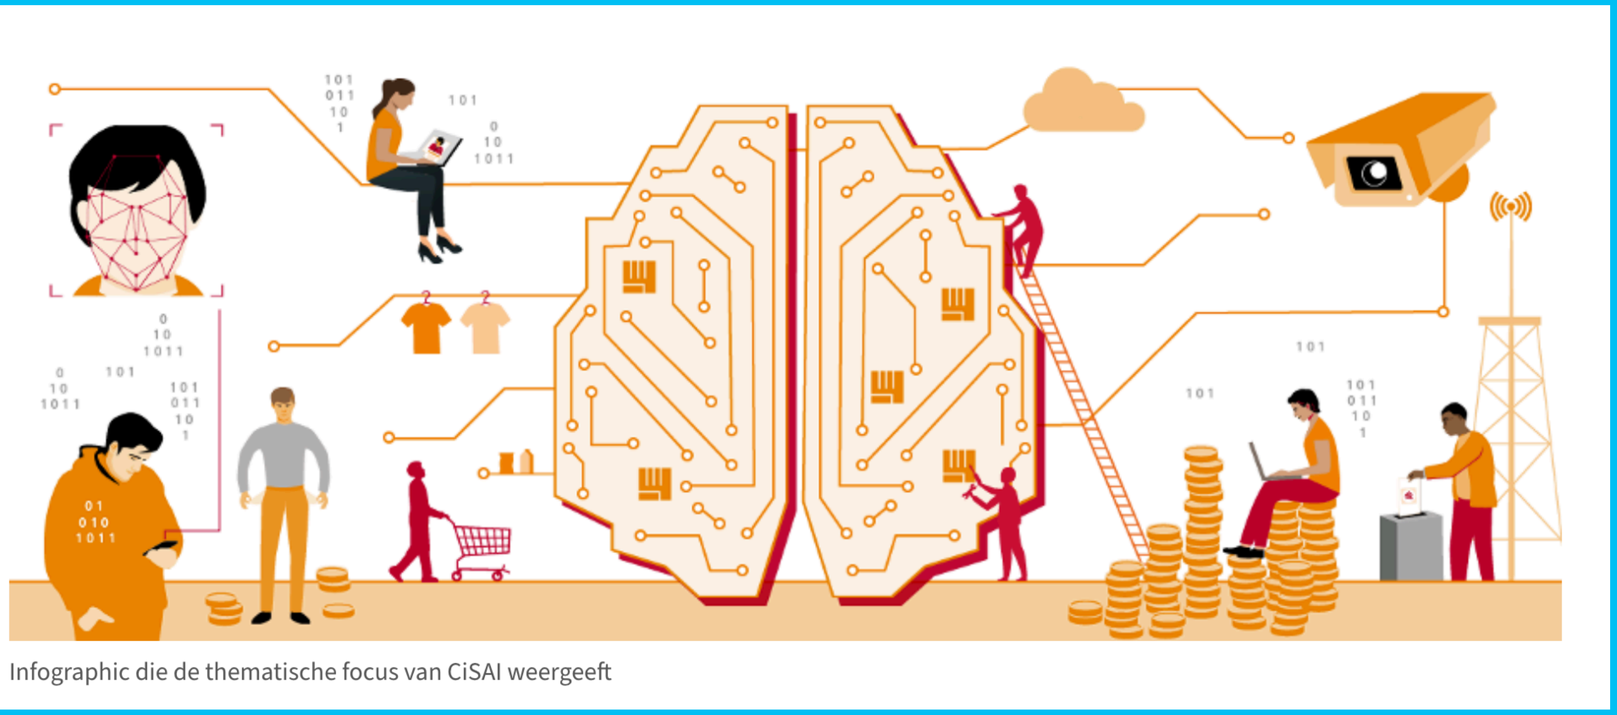
BA BETA GAMMA

AI & SAMENLEVING

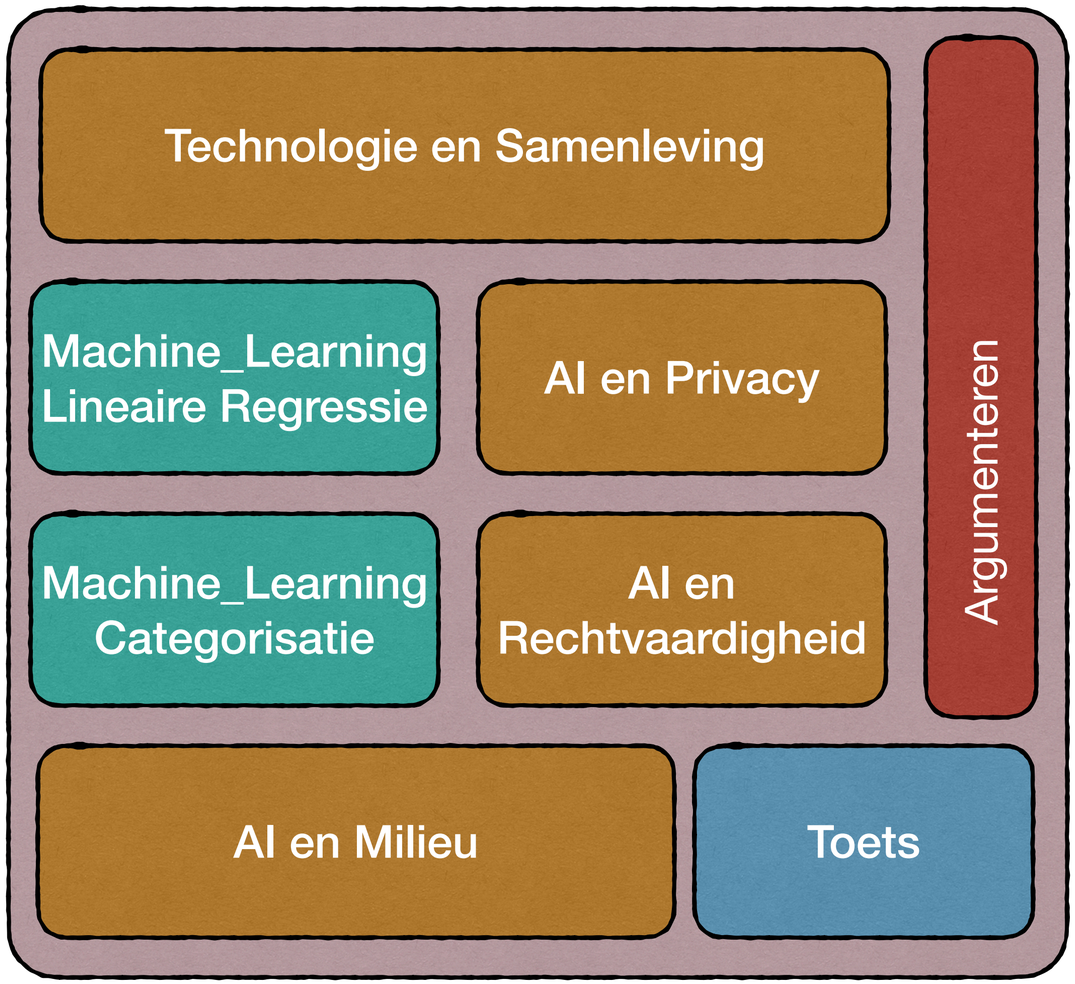
HC 2: MACHINE LEARNING, DEEL 1

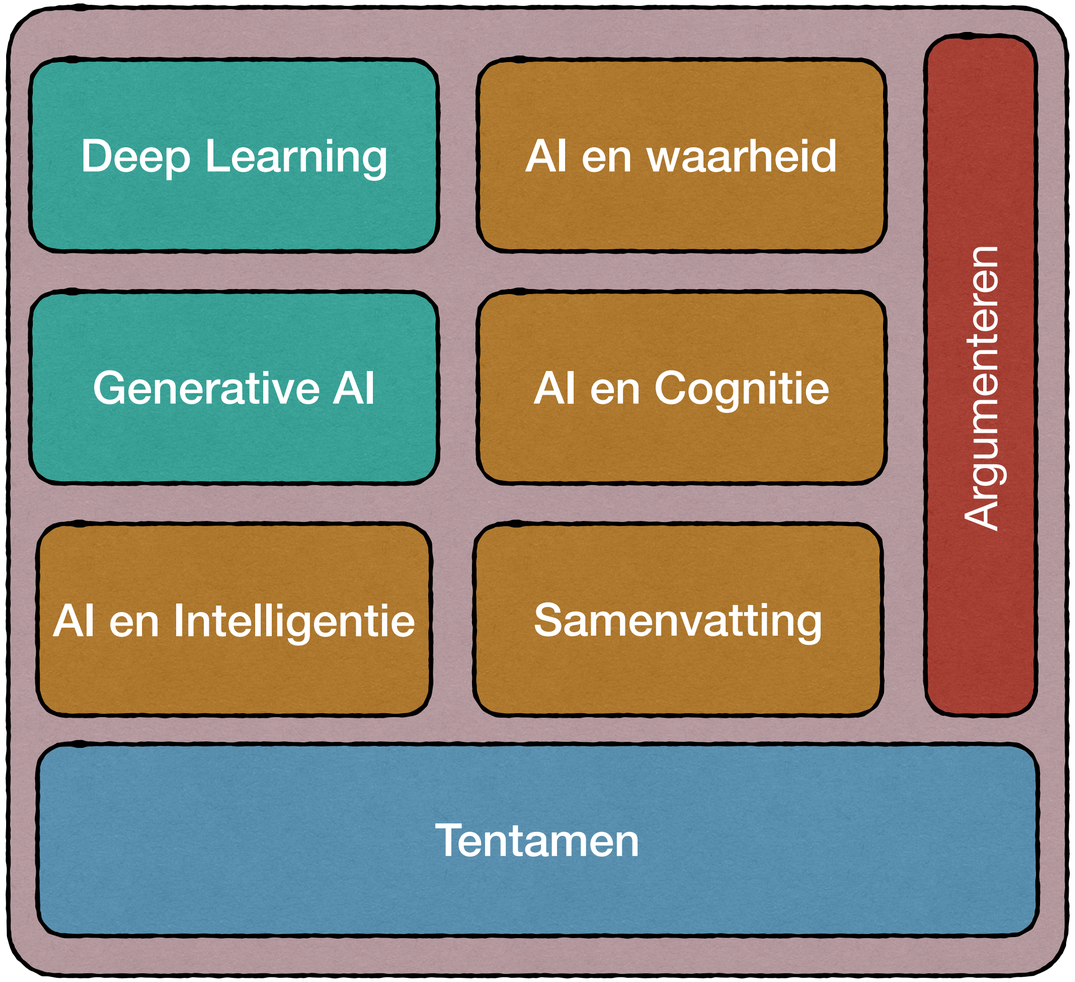


Infographic die de thematische focus van CiSAI weergeeft

Inleiding

Planning





Hoorcollege 2

Opbouw

Deel 1: Machine Learning

- Lineaire regressie: idee
- Wiskundig interlude: partiële afgeleide
- Wij gaan rekenen.

Deel 2: Privacy

- Wat is privacy?
- Waarom willen wij privacy?
- Privacy en AI
- Privacy en Vrijheid

Hoorcollege 2

Leerdoel vandaag

Wat kun je aan het eind van de les?

1. Uitleggen wat lineaire regressie is en hoe het werkt.
2. Lineaire regressie op een gegeven dataset toepassen.
3. Uitleggen wat privacy is en welke functie privacy heeft.
4. Evalueren hoe bepaalde AI praktijken of applicaties privacy beperken en een positie betrekken tot het gebruik van deze praktijken/applicaties.
5. Positieve en negatieve vrijheid onderscheiden en herkennen wanneer deze begrippen van toepassing zijn

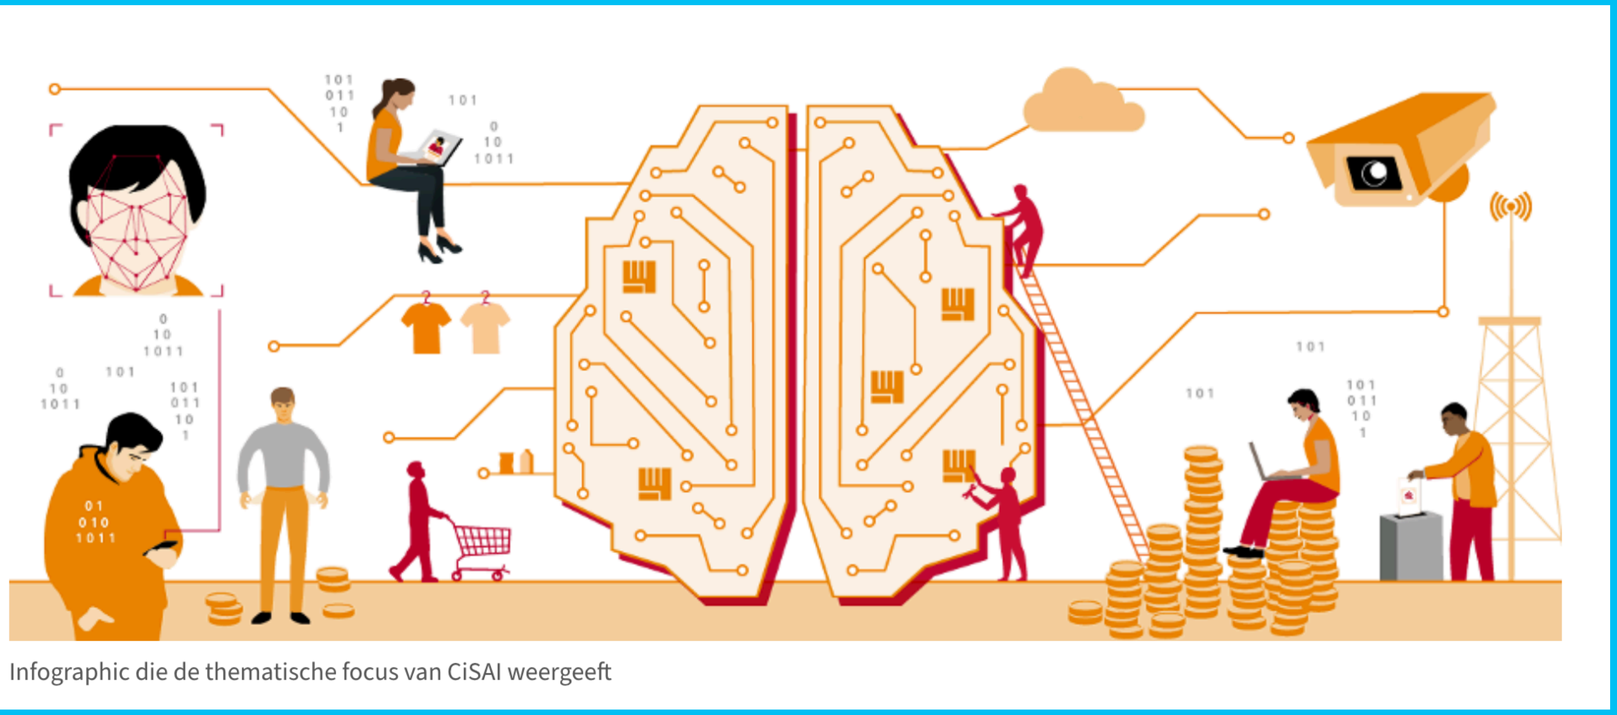
Sleutelbegrippen

- ➡ Lineaire regressie
- ➡ Squared error loss function
- ➡ Partiële afgeleide
- ➡ Privacy
- ➡ Positieve/negatieve vrijheid

BA BETA GAMMA

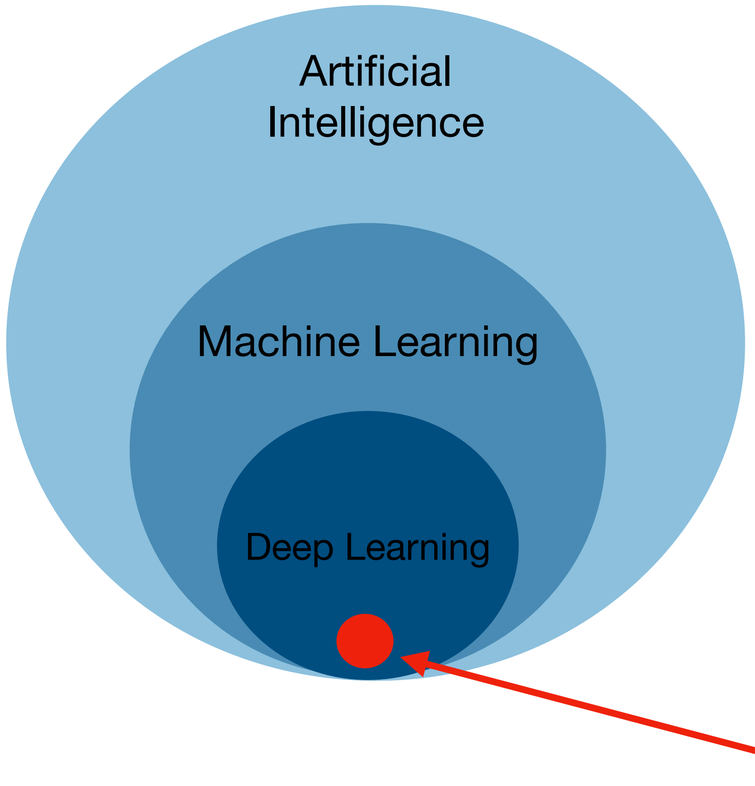
AI & SAMENLEVING

HC 2: MACHINE LEARNING, DEEL 1



Infographic die de thematische focus van CiSAI weergeeft

Artificial Intelligence



“Ability of computers to perform tasks commonly associated with humans.”

Programs that help machines to learn and adapt without explicit instructions.

A particular method of machine learning involving neural networks

Twee types van AI - twee types cognitie

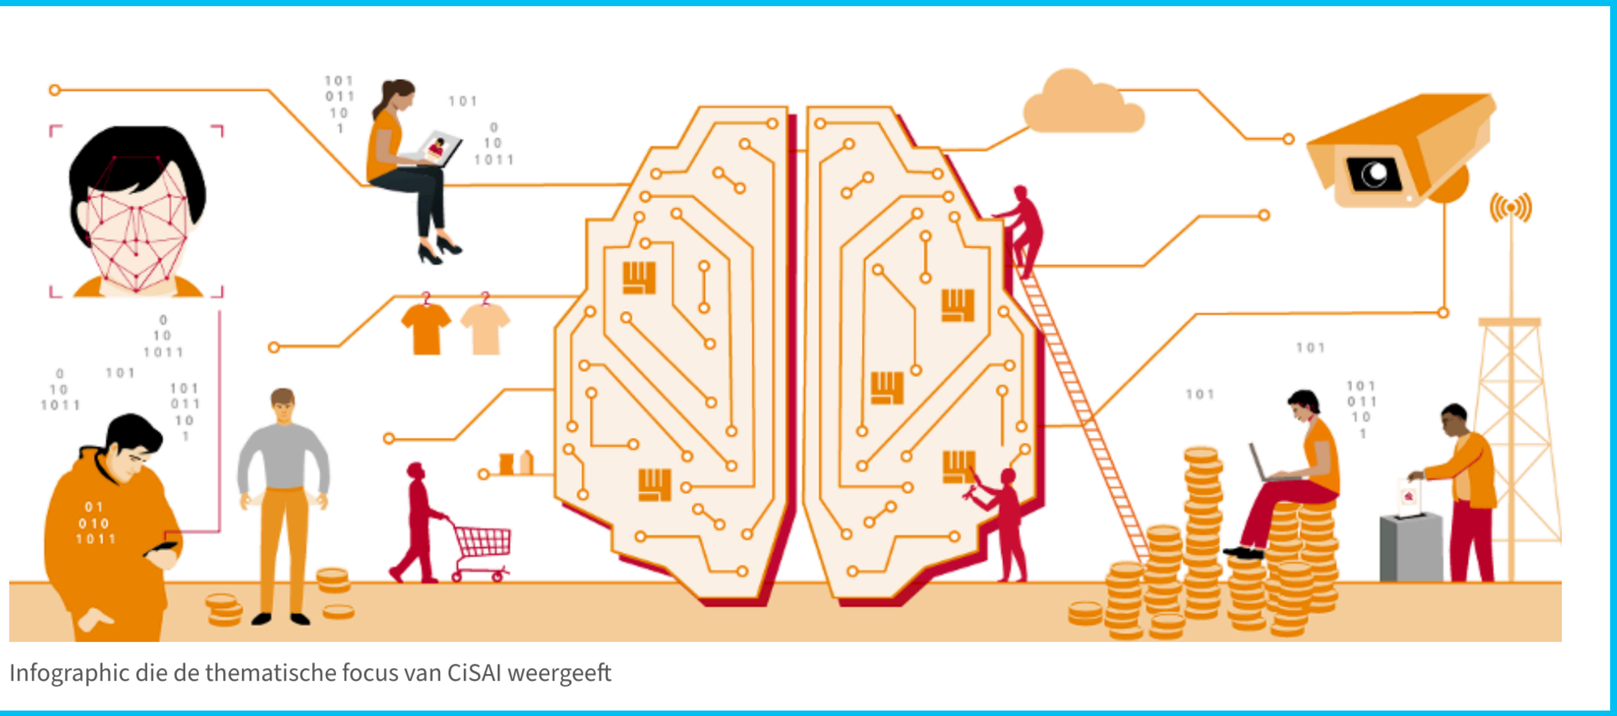
Symbolic AI

Sub-symbolic AI

- We botsen direct het brein na, en daarmee al onze cognitive processen
- We leren de machine niet wat zij moeten leren, maar laten zij dat zelf ontdekken (ML)
- Geïnspireerd door neuroscience en psychologie van leren
- Neuronale netwerken
- Tegenwoordig sterk dominant in AI
- Gebaseerd op equation-solving, numerisch
- Niet transparent/explanatory

MACHINE LEARNING DEEL 1

LINEAIRE REGRESSIE



Infographic die de thematische focus van CiSAI weergeeft

Machine Learning

Leren om te voorspellen

- Het doel is het maken van voorspellingen (weer, diagnose, stemherkenning).
- Hiervoor hebben wij een theorie nodig.
- ML gaat over het bouwen van algoritmen die op basis van data zelf theorieën kunnen vinden (leren).
- Deze theorieën zijn wiskundige formules.
- Een goede theorie = goede (correcte) voorspellingen.

Machine Learning

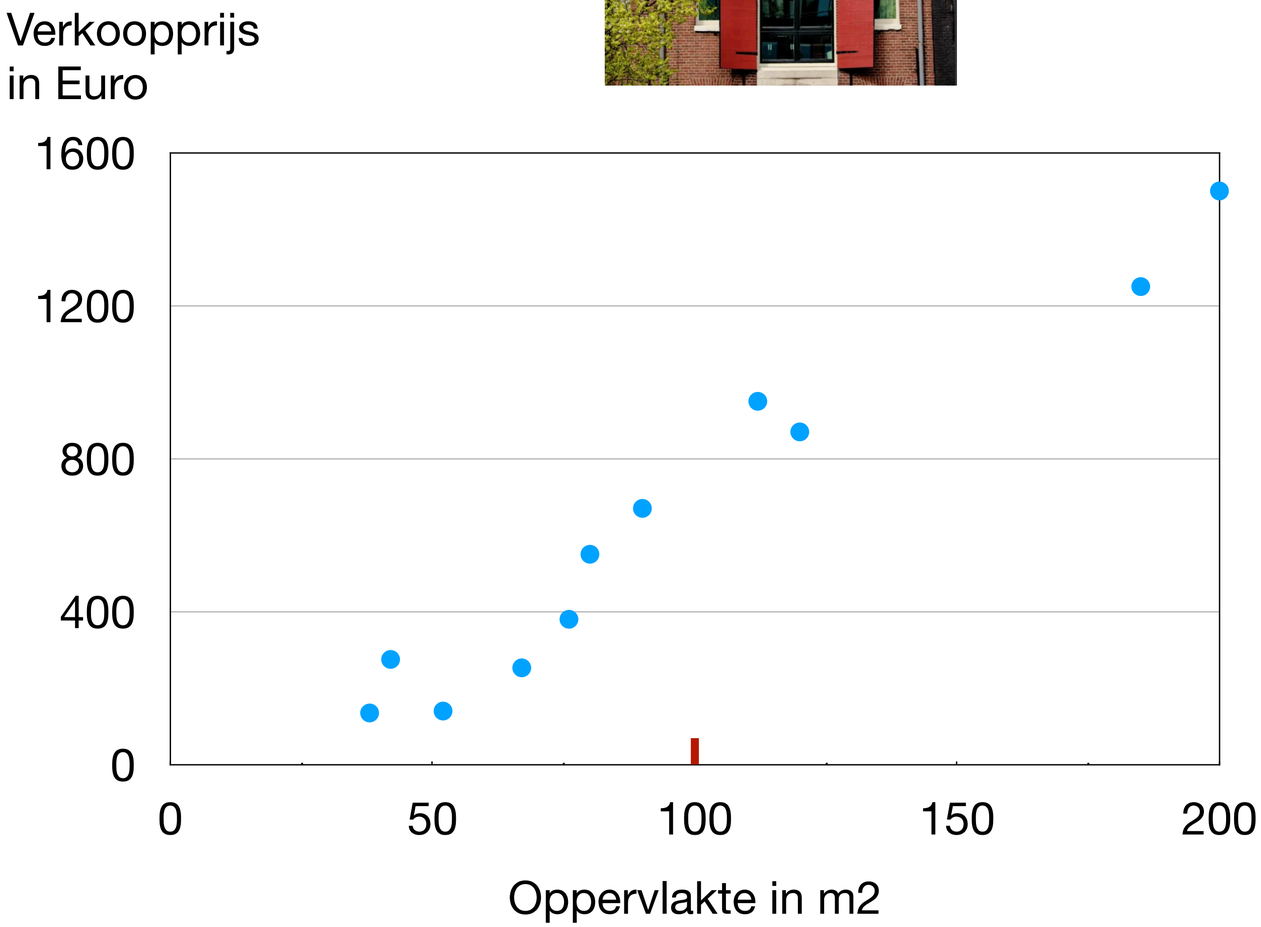
Een voorbeeld: huisprijzen



Ik heb een huis van 100m2 - hoeveel kan ik ervoor vragen?

Data

	Input feature X: Oppervlakte in m2	Output feature Y: Verkoopprijs in E
1	38	135.000
2	42	275.000
3	52	140.000
4	67	253.000
5	76	380.000
6	80	550.000
7	90	670.000
8	112	950.000
9	120	870.000
10	185	1.250.000
11	200	1.500.000



Machine Learning

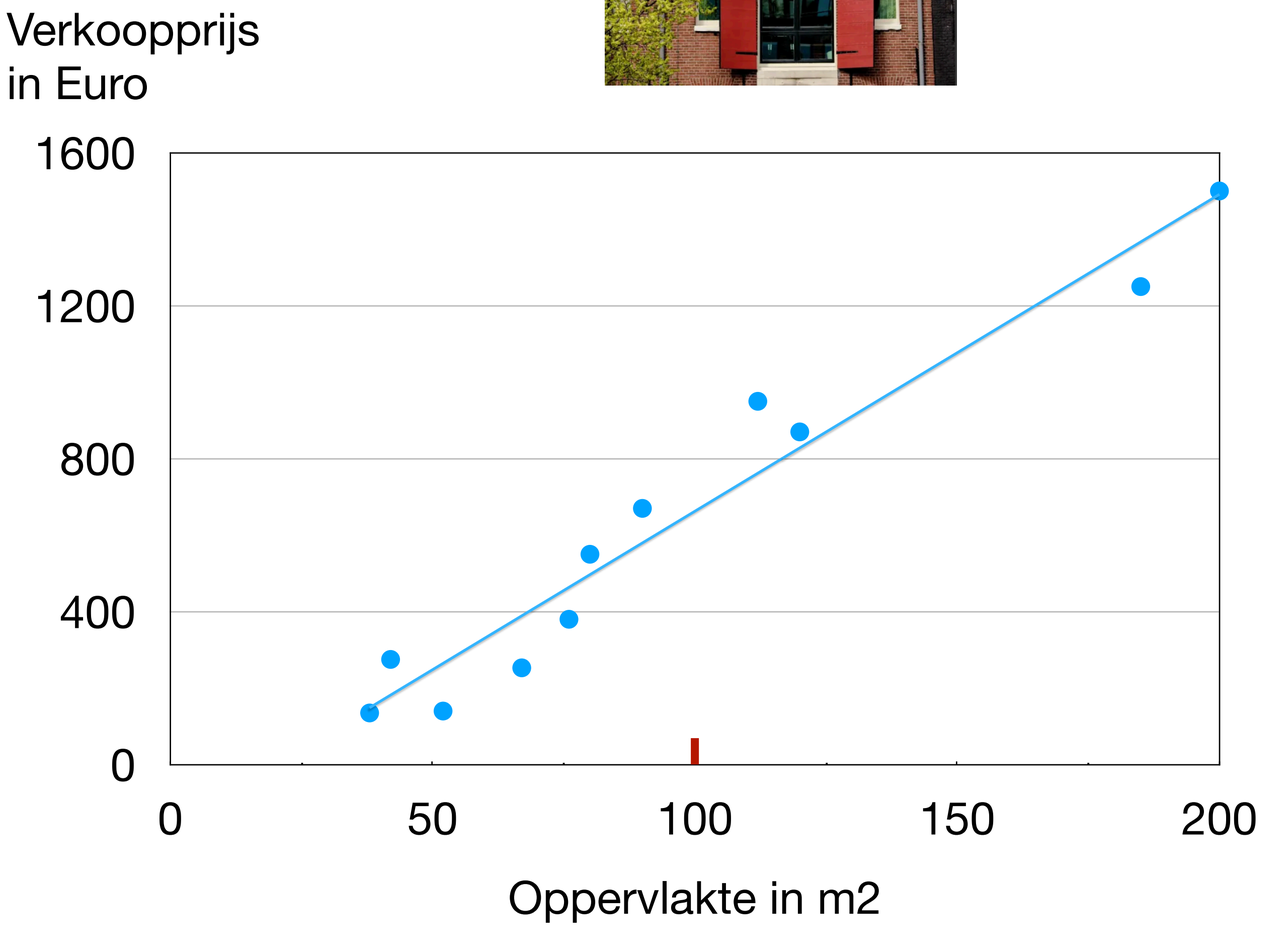
Een voorbeeld: huisprijzen



Ik heb een huis van 100m2 - hoeveel kan ik ervoor vragen?

Data

	Input feature X	Output feature Y
	Oppervlakte in m2	**Verkoopprijs in E**
1	38	135.000
2	42	275.000
3	52	140.000
4	67	253.000
5	76	380.000
6	80	550.000
7	90	670.000
8	112	950.000
9	120	870.000
10	185	1.250.000
11	200	1.500.000



Machine Learning

Een voorbeeld: huisprijzen

Ik heb een huis van 100m2 - hoeveel kan ik ervoor vragen?

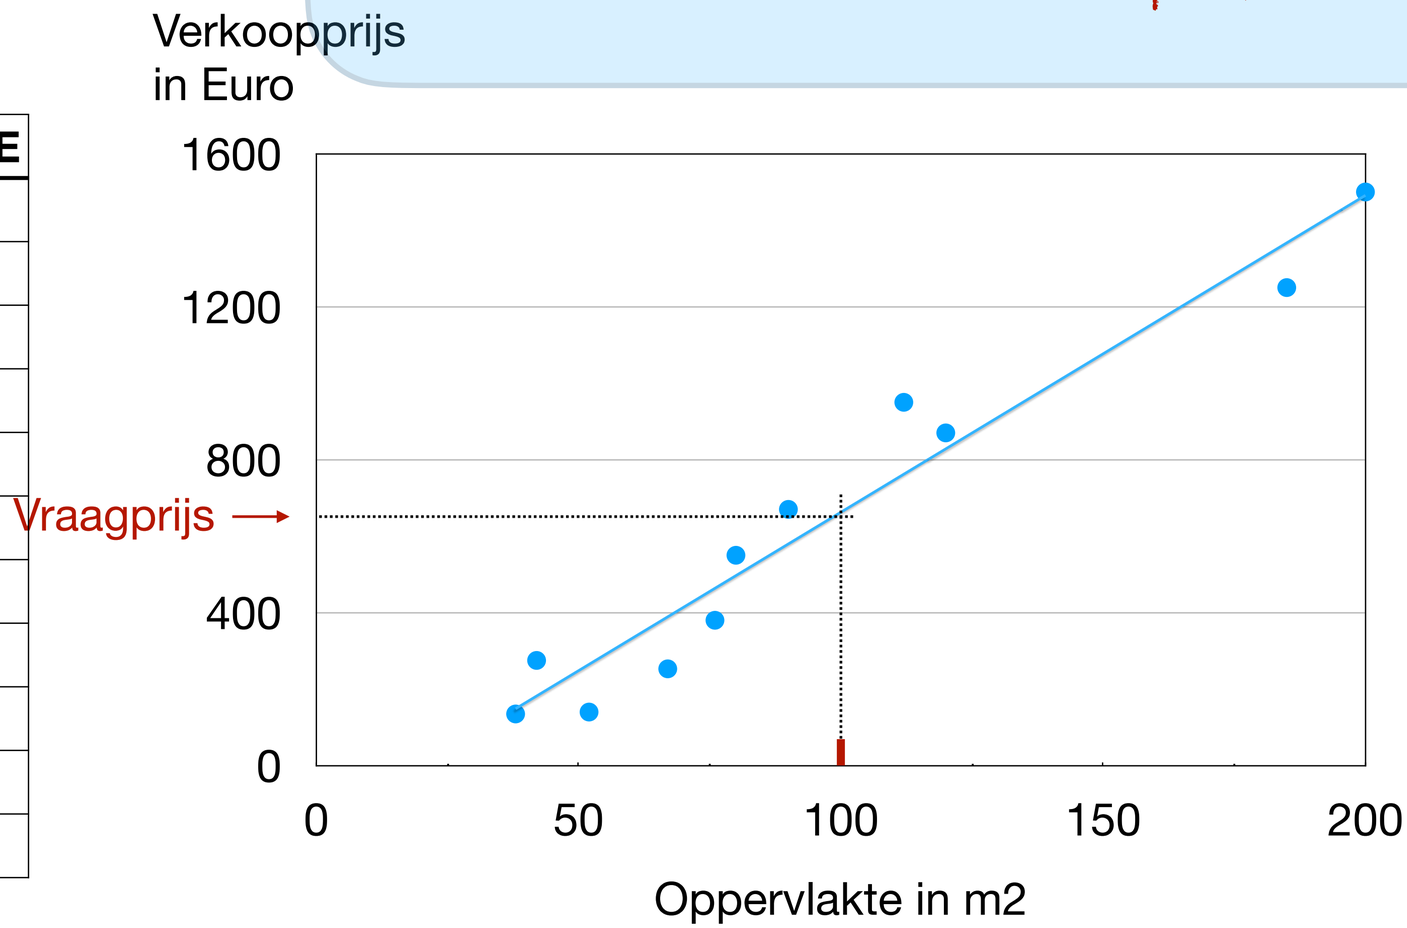
Gezocht: **lineaire functie** $\hat{y} = wx + b$

Dit noemen wij een lineair model

Het voorspeld output features voor nieuwe input features.

Data

	Input feature X: Oppervlakte in m2	Output feature Y: Verkoopprijs in E
1	38	135.000
2	42	275.000
3	52	140.000
4	67	253.000
5	76	380.000
6	80	550.000
7	90	670.000
8	112	950.000
9	120	870.000
10	185	1.250.000
11	200	1.500.000



Machine Learning

Een voorbeeld: huisprijzen

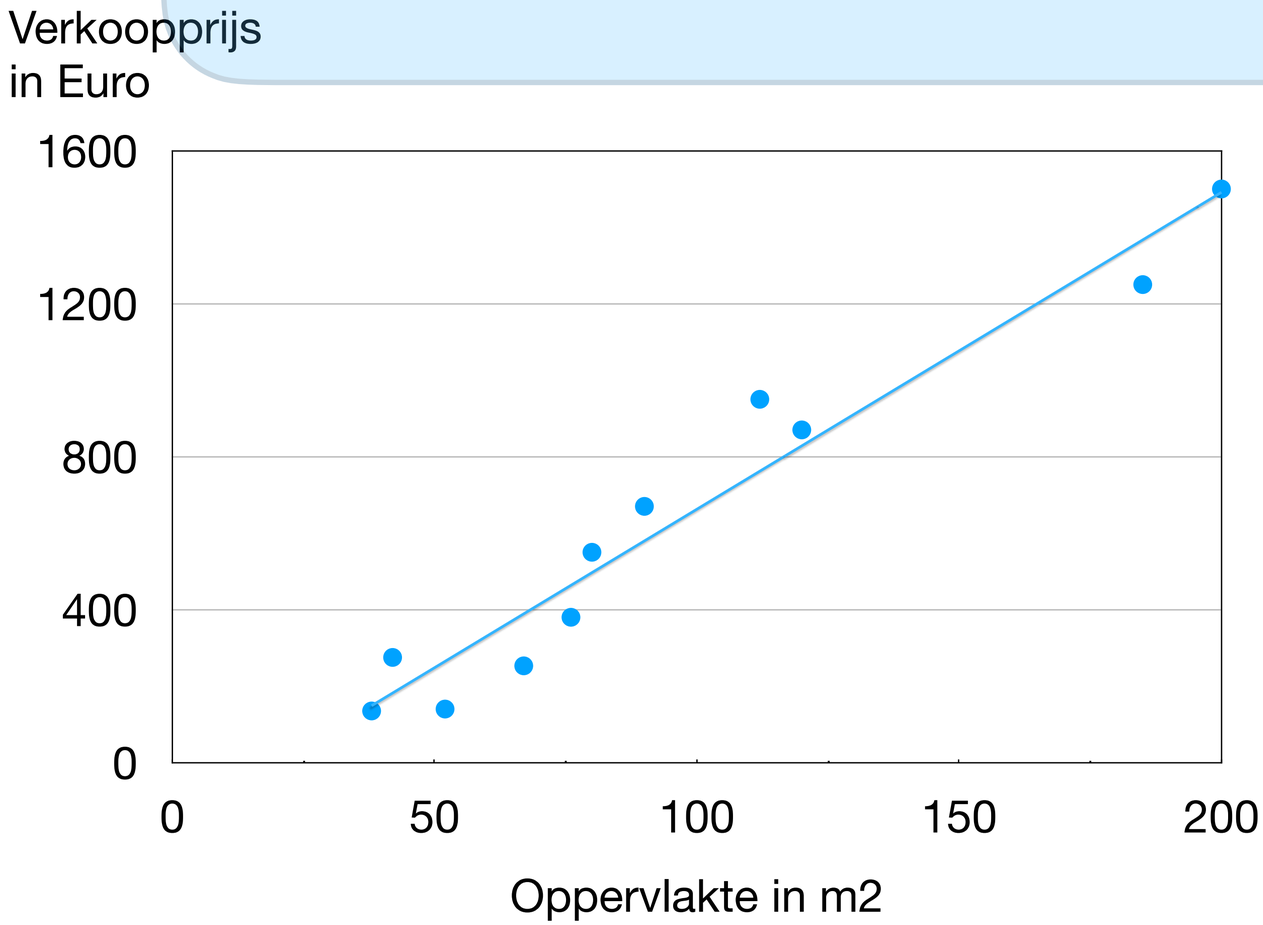
Ik heb een huis van 100m2 - hoeveel kan ik ervoor vragen?

Gezocht: **lineaire functie** $\hat{y} = wx + b$

parameters

Data

	Input feature X	Output feature Y
	Oppervlakte in m2	**Verkoopprijs in E**
1	38	135.000
2	42	275.000
3	52	140.000
4	67	253.000
5	76	380.000
6	80	550.000
7	90	670.000
8	112	950.000
9	120	870.000
10	185	1.250.000
11	200	1.500.000



Machine Learning

Een voorbeeld: huisprijzen

Ik heb een huis van 100m2 - hoeveel kan ik ervoor vragen?

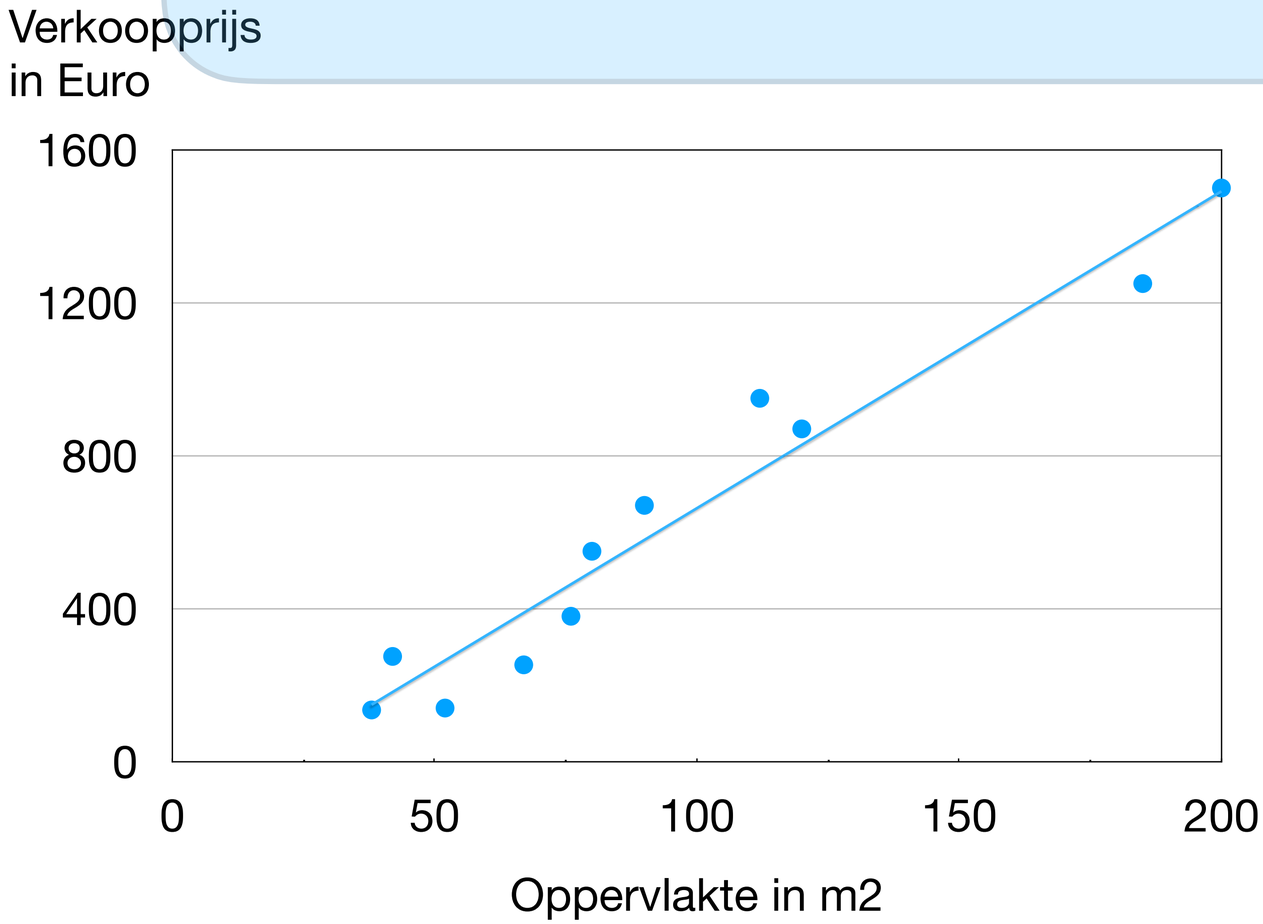
Gezocht: **lineaire functie** $\hat{y} = wx + b$

Weight

Bias

Data

	Input feature X	Output feature Y
	Oppervlakte in m2	**Verkoopprijs in E**
1	38	135.000
2	42	275.000
3	52	140.000
4	67	253.000
5	76	380.000
6	80	550.000
7	90	670.000
8	112	950.000
9	120	870.000
10	185	1.250.000
11	200	1.500.000



Machine Learning

Een voorbeeld: huisprijzen

Ik heb een huis van 100m2 - hoeveel kan ik ervoor vragen?

Gezocht: **lineaire functie** $\hat{y} = wx + b$

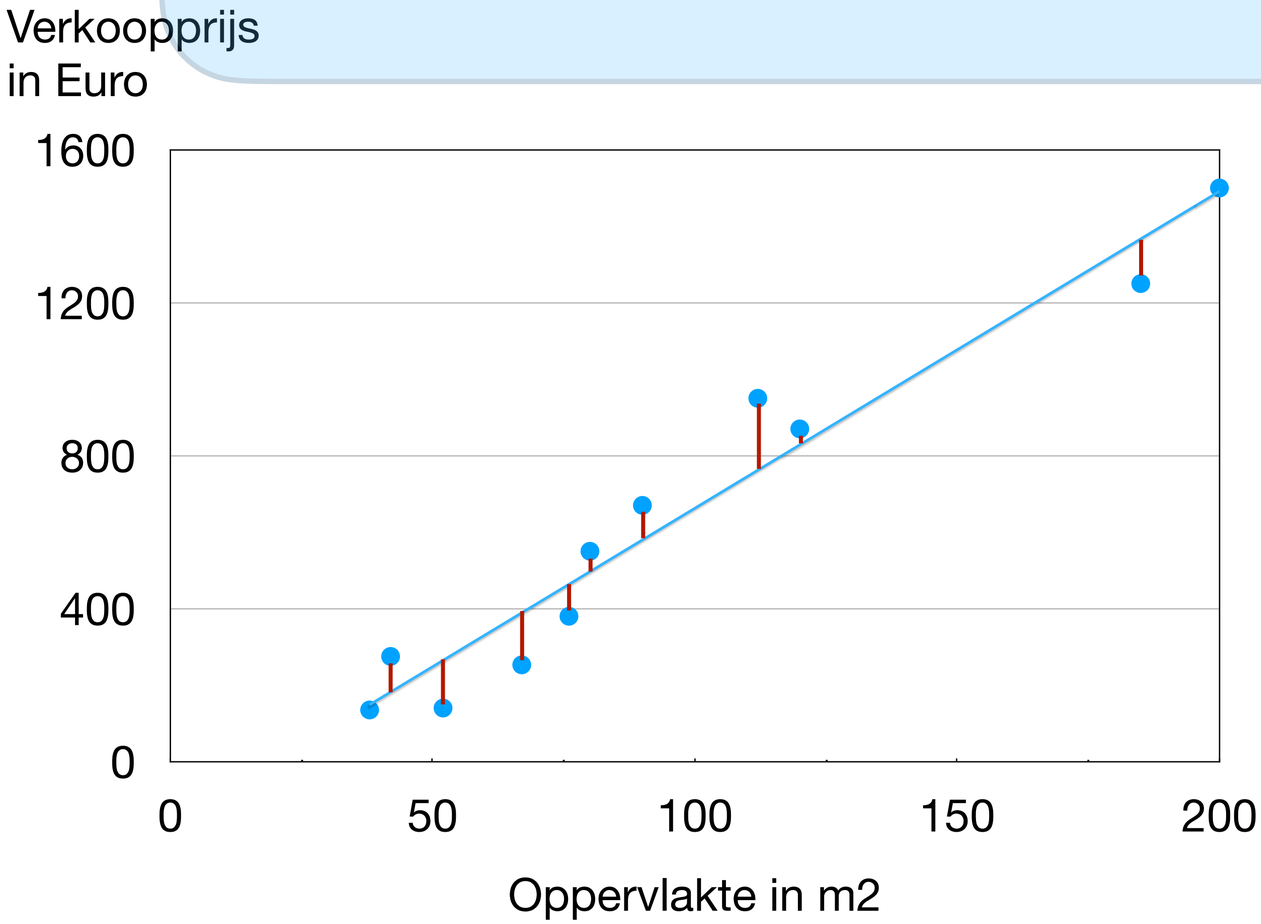
Loss function
(Squared error loss function)

$$Loss = \frac{1}{2}\Sigma_{j=1}^{N}(y_j - \hat{y}_j)^2$$

$$= \frac{1}{2}\Sigma_{j=1}^{N}(y_j - (wx_j + b))^2$$

Data

	Input feature X: Oppervlakte in m2	Output feature Y: Verkoopprijs in E
1	38	135.000
2	42	275.000
3	52	140.000
4	67	253.000
5	76	380.000
6	80	550.000
7	90	670.000
8	112	950.000
9	120	870.000
10	185	1.250.000
11	200	1.500.000



Machine Learning

Een voorbeeld: huisprijzen

Ik heb een huis van 100m2 - hoeveel kan ik ervoor vragen?

Data

	Input feature X	Output feature Y
	Oppervlakte in m2	**Verkoopprijs in E**
1	38	135.000
2	42	275.000
3	52	140.000
4	67	253.000
5	76	380.000
6	80	550.000
7	90	670.000
8	112	950.000
9	120	870.000
10	185	1.250.000
11	200	1.500.000

Gezocht: **lineaire functie** $\hat{y} = wx + b$

Loss function
(Squared error loss function)

$$Loss = \frac{1}{2}\Sigma_{j=1}^{N}(y_j - \hat{y}_j)^2$$

$$= \frac{1}{2}\Sigma_{j=1}^{N}(y_j - (wx_j + b))^2$$

Wij moeten dus:

- Bepalen voor welke waardes van de parameters de loss functie **minimaal** is.

Dus:

- De eerste afgeleide van de loss functie berekenen, gelijk zetten aan nul, en oplossen naar w en b.

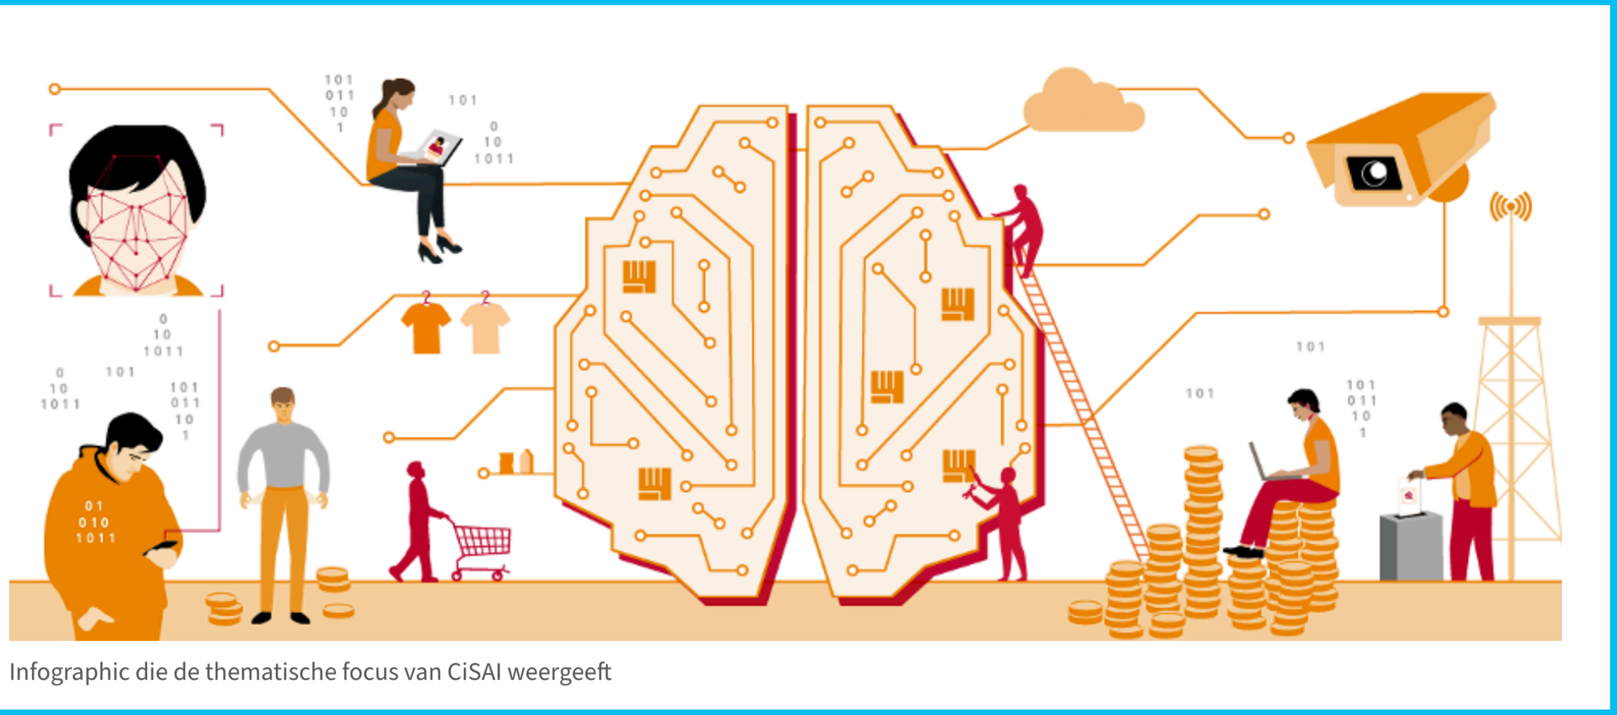
Dit kunnen voor functies zoals deze ...

$$Loss(w) = \frac{1}{2}\Sigma_{j=1}^{N}(y_j - wx_j)^2$$

... maar hoe doen wij dit voor functies met twee variabelen???

MACHINE LEARNING DEEL 1

PARTIËLE AFGELEIDE



Infographic die de thematische focus van CiSAI weergeeft

Partial derivative/ partiële afgeleide

Wiskundig uitstapje

Gegeven is een functie f met n variabelen $x_1, \ldots, x_n$

- De **partiële afgeleide** van f naar x_1 is de afgeleide van f naar x_1, waarbij alle andere variabelen als constanten worden behandeld.
- Alle regels voor de afgeleide (kettenregel, productregel, …) zijn van toepassing.
- De afgeleide (gradient) van f is de vector van de partiële afgeleide van f.

$$\overrightarrow{\nabla_{\vec{x}} f} = grad\ f = \frac{df}{d\vec{x}} = [\frac{\partial f}{\partial x_1} \ \ldots \ \frac{\partial f}{\partial x_n}]$$

Voorbeeld $f(x, y) = x^2 + sin(2y)$

Functie met twee variabelen

$$\frac{\partial f}{\partial x} = 2x \qquad \frac{\partial f}{\partial y} = 2cos(2y)$$

$$\overrightarrow{\nabla f} = \frac{df}{d\vec{x}} = [2x \ 2cos(2y)]$$

Partial derivative/ partiële afgeleide

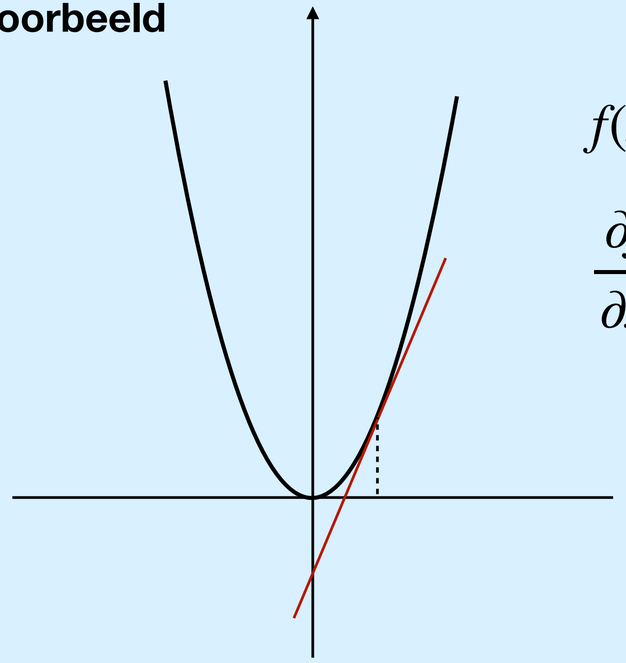
Wiskundig uitstapje

Wat heb je aan een afgeleide?

- Het vertelt je wat de ratio van verandering in y is relatief tot x.
- Dus de stijging van de aanliggende lijn in x.
- De afgeleide is nul in het minimum/ maximum van de functie.
- De afgeleide is positief als de functie stijgt, en negatie als de functie daalt.

Dit geldt net zo goed voor partiële afgeleide.

Voorbeeld

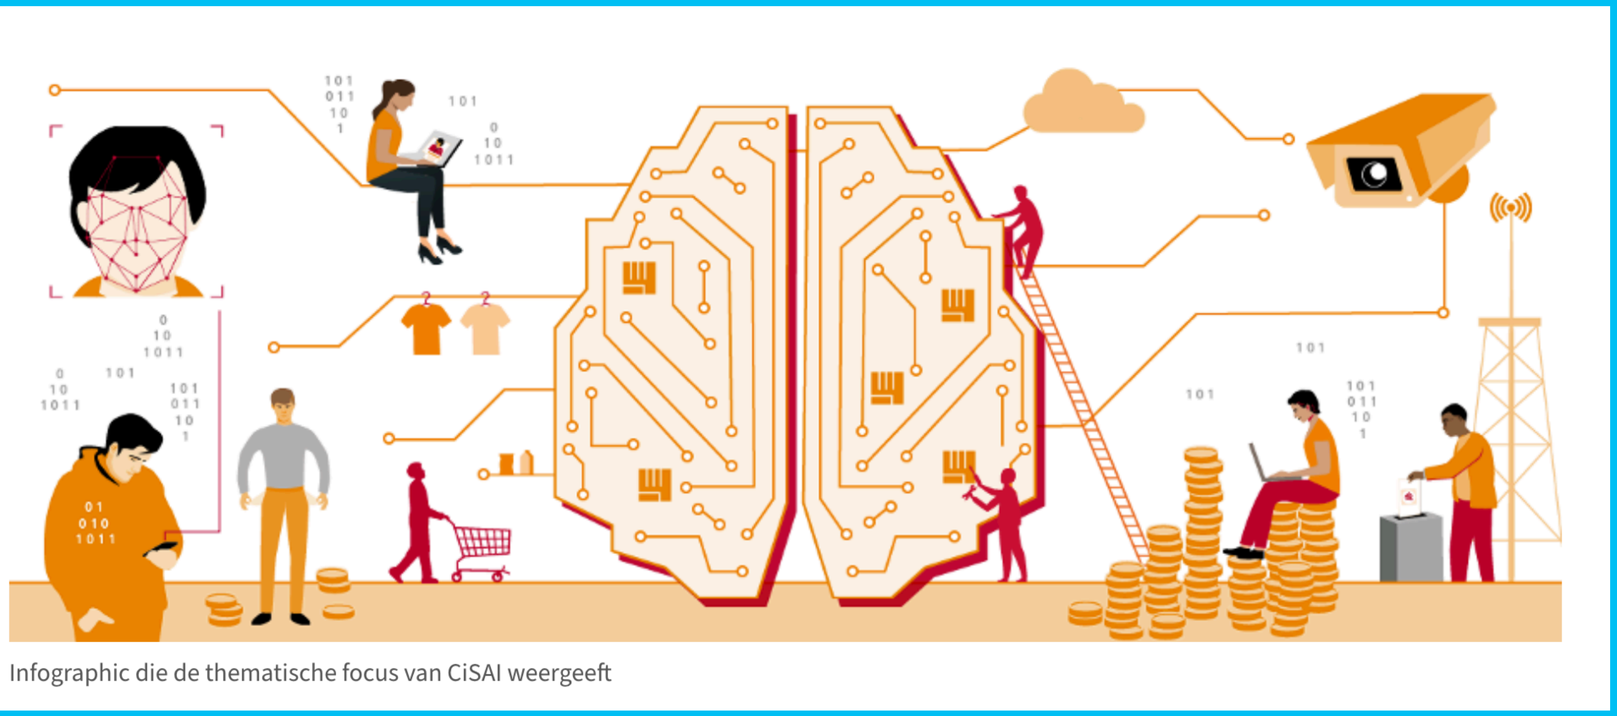


$$f(x) = x^2$$

$$\frac{\partial f}{\partial x} = 2x$$

MACHINE LEARNING DEEL 1

TERUG NAAR LINEAIRE REGRESSIE



Infographic die de thematische focus van CiSAI weergeeft

Machine Learning

Een voorbeeld: huisprijzen

Ik heb een huis van 100m2 - hoeveel kan ik ervoor vragen?

Data

	Input feature X	Output feature Y
	Oppervlakte in m2	**Verkoopprijs in E**
1	38	135.000
2	42	275.000
3	52	140.000
4	67	253.000
5	76	380.000
6	80	550.000
7	90	670.000
8	112	950.000
9	120	870.000
10	185	1.250.000
11	200	1.500.000

Gezocht: **lineaire functie** $\hat{y} = wx + b$

Loss function
(Squared error loss function)

$$Loss = \frac{1}{2}\Sigma_{j=1}^{N}(y_j - \hat{y}_j)^2$$

$$= \frac{1}{2}\Sigma_{j=1}^{N}(y_j - (wx_j + b))^2$$

Wij moeten:

- Bepalen voor welke waardes van de parameters de loss functie **minimaal** is.

Dus:

- De eerste afgeleide van de loss functie berekenen, gelijk zetten aan nul, en oplossen naar w.

$$b = \frac{1}{N}(\Sigma_{j=1}^{N}y_j - w\Sigma_{j=1}^{N}x_j)$$

$$w = \frac{N\Sigma_{j=1}^{N}x_j y_j - \Sigma_{j=1}^{N}y_j\Sigma_{j=1}^{N}x_j}{N\Sigma_{j=1}^{N}x_j^2 - (\Sigma_{j=1}^{N}x_j)^2}$$

Machine Learning

Een voorbeeld: huisprijzen

Ik heb een huis van 100m2 - hoeveel kan ik ervoor vragen?

Data

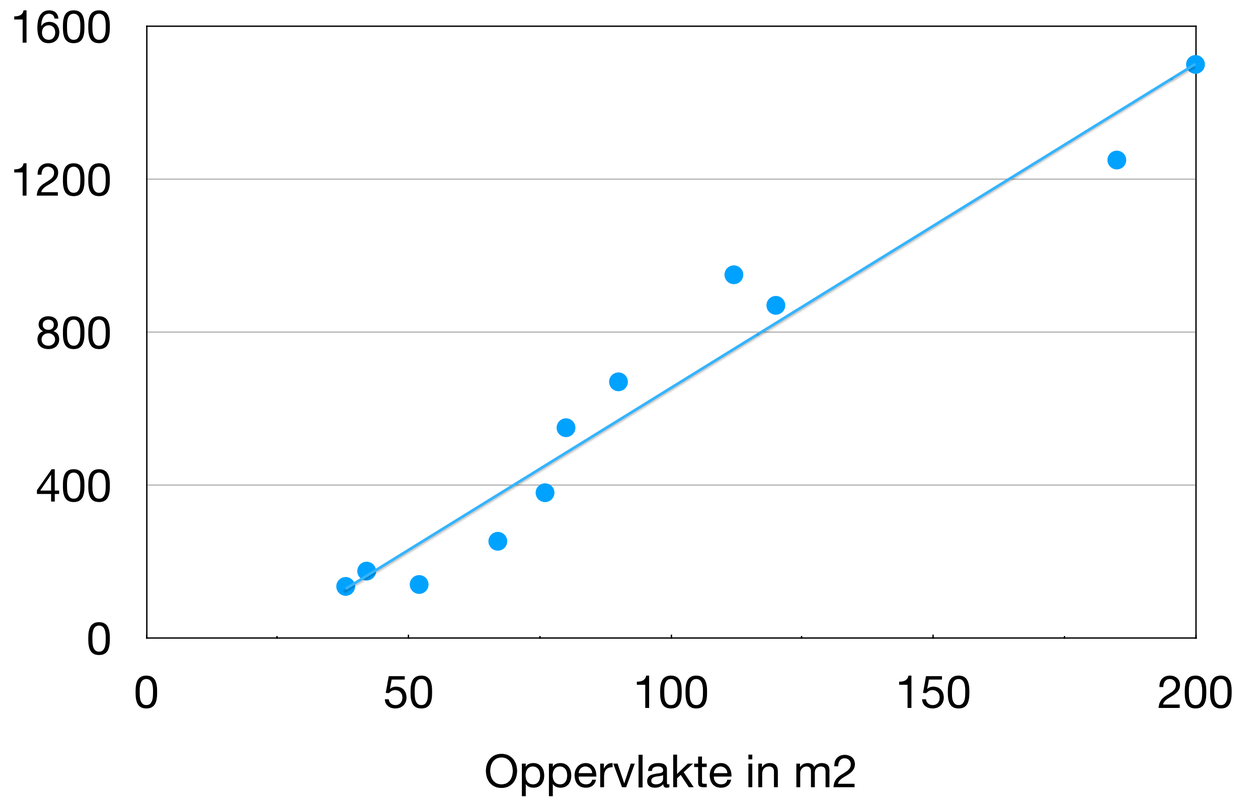
	Input feature X	Output feature Y
	Oppervlakte in m2	**Verkoopprijs in E**
1	38	135.000
2	42	275.000
3	52	140.000
4	67	253.000
5	76	380.000
6	80	550.000
7	90	670.000
8	112	950.000
9	120	870.000
10	185	1.250.000
11	200	1.500.000

$$w = \frac{N\Sigma_{j=1}^{N} x_j y_j - \Sigma_{j=1}^{N} y_j \Sigma_{j=1}^{N} x_j}{N\Sigma_{j=1}^{N} x_j^2 - (\Sigma_{j=1}^{N} x_j)^2} = 8{,}473$$

$$b = \frac{1}{N}(\Sigma_{j=1}^{N} y_j - w\Sigma_{j=1}^{N} x_j) = -193{,}21$$

Dit is het lineair model

Gezocht: **lineaire functie** $\hat{y} = 8{,}473x - 193{,}21$



Machine Learning

Een voorbeeld: huisprijzen

Ik heb een huis van 100m2 - hoeveel kan ik ervoor vragen?

$$\hat{y} = 8{,}473x - 193{,}21$$

$$\hat{y} = 8{,}473 * 100 - 193{,}21 = 654{,}090$$

Voor 100m2 kan ik 654.090 E vragen …

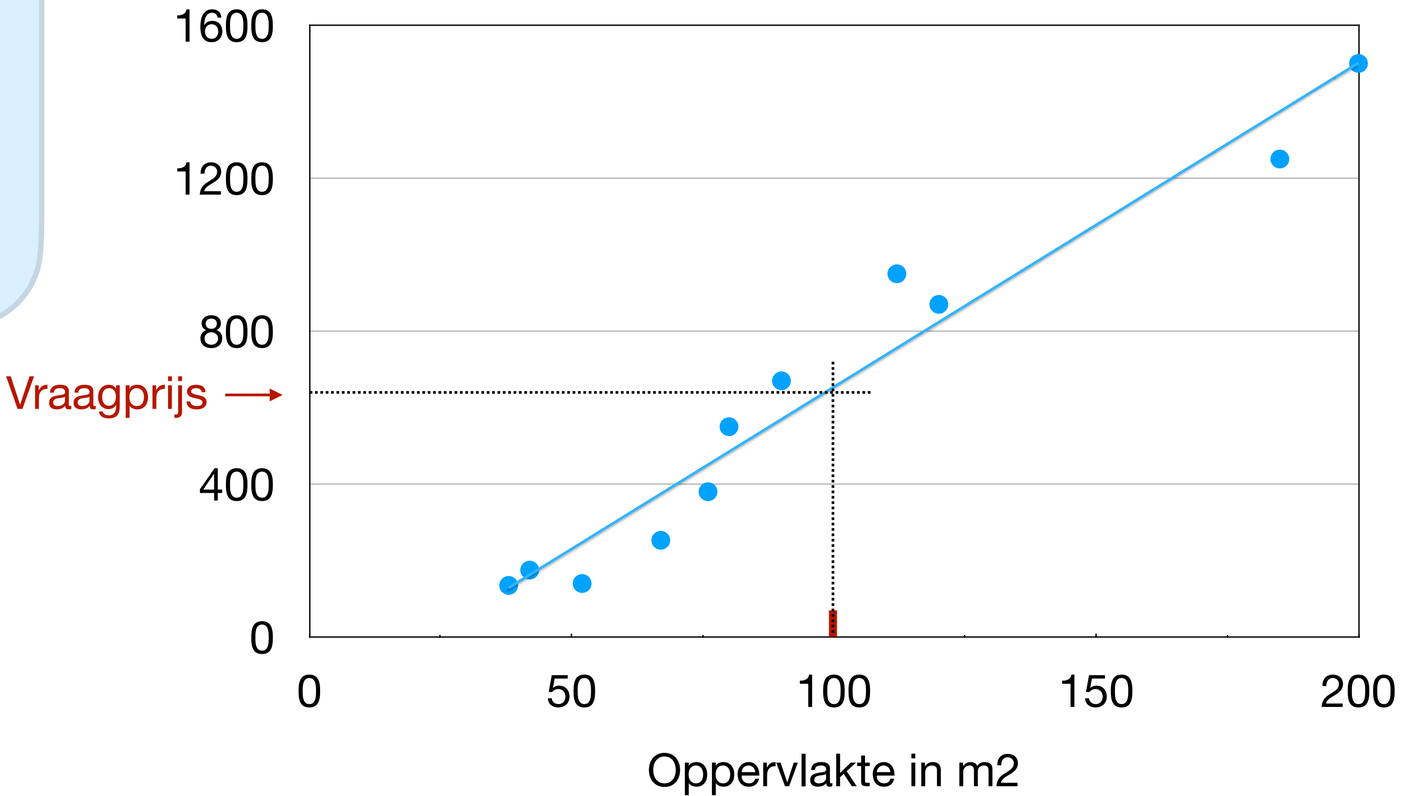
… volgens dit model.

$$w = \frac{N\Sigma_{j=1}^{N} x_j y_j - \Sigma_{j=1}^{N} y_j \Sigma_{j=1}^{N} x_j}{N\Sigma_{j=1}^{N} x_j^2 - (\Sigma_{j=1}^{N} x_j)^2} = 8{,}473$$

$$b = \frac{1}{N}(\Sigma_{j=1}^{N} y_j - w\Sigma_{j=1}^{N} x_j) = -193{,}21$$

Dit is het lineair model

Gezocht: **lineaire functie** $\hat{y} = 8{,}473x - 193{,}21$



Machine Learning

Lineaire Regressie

Gezocht: **lineaire functie** $\hat{y} = wx + b$

parameters

Loss function
(Squared error loss function)

$$Loss = \frac{1}{2}\Sigma_{j=1}^{N}(y_j - \hat{y})^2$$

$$= \frac{1}{2}\Sigma_{j=1}^{N}(y_j - (wx_j + b))^2$$

Wij moeten dus:

1. Bepalen voor welke waardes van de parameters de Loss function minimaal is.
2. D.w.z. het minimum van de Loss functie zoeken ten opzichte van w (weight) en b (bias).
3. D.w.z. afgeleide van Loss bepalen ten opzichte van w en b.
4. … dan de afgeleide gelijk aan nul zetten …
5. … dan de vergelijking oplossen naar w en b.

$$w = \frac{N\Sigma_{j=1}^{N}x_j y_j - \Sigma_{j=1}^{N}y_j \Sigma_{j=1}^{N}x_j}{N\Sigma_{j=1}^{N}x_j^2 - (\Sigma_{j=1}^{N}x_j)^2} = 8{,}473$$

$$b = \frac{1}{N}(\Sigma_{j=1}^{N}y_j - w\Sigma_{j=1}^{N}x_j) = -193{,}21$$

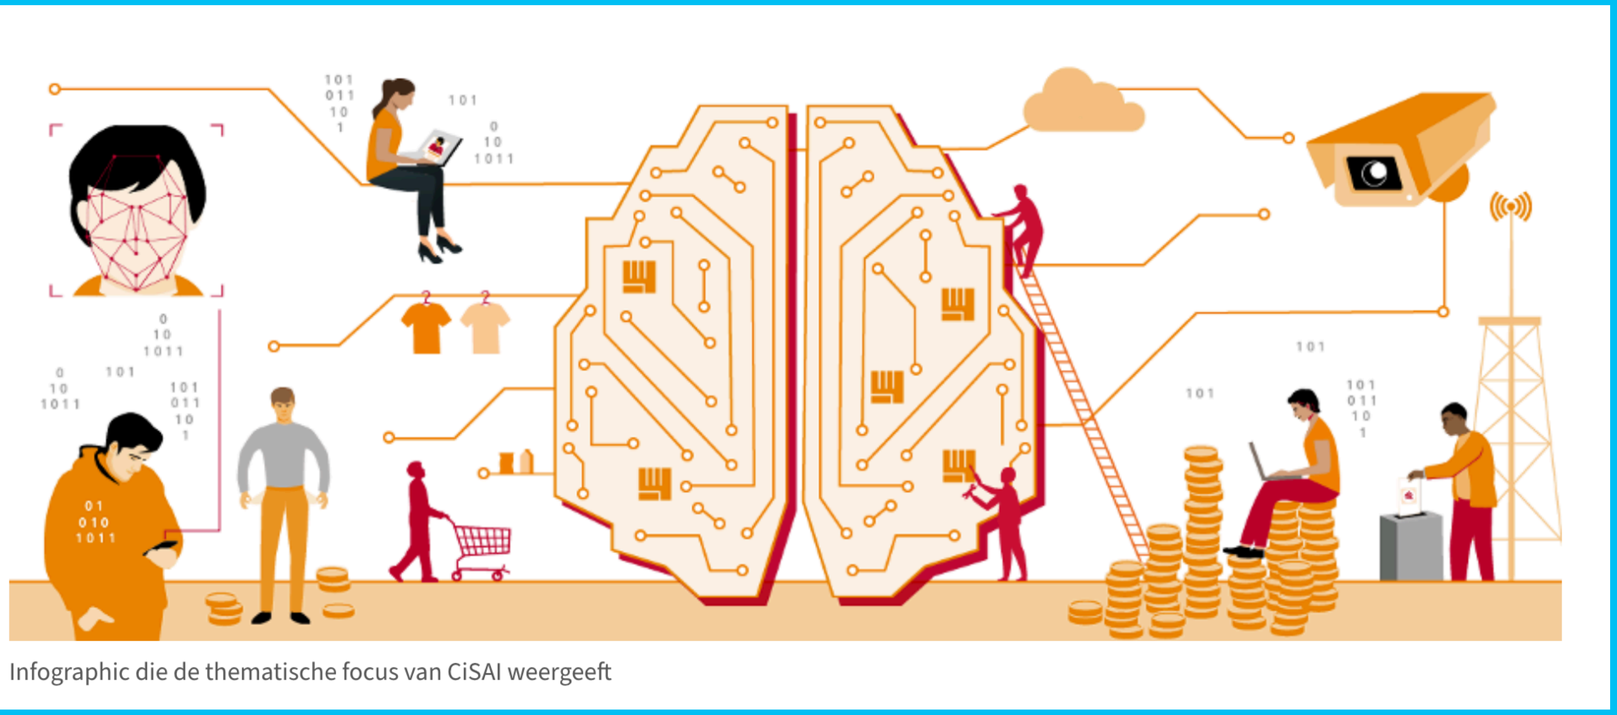
Lineair model: $\hat{y} = wx + b$

- Dit kun je op elke dataset toepassen.
- Je kunt ook de loss op een andere manier bepalen …
- … of een andere functie willen fitten.

Maar wat doen we als we geen afgeleide kunnen bepalen of de vergelijkingen niet kunnen oplossen???

MACHINE LEARNING DEEL 1

HET MODEL EVALUEREN



Infographic die de thematische focus van CiSAI weergeeft

Machine Learning

Een model evalueren

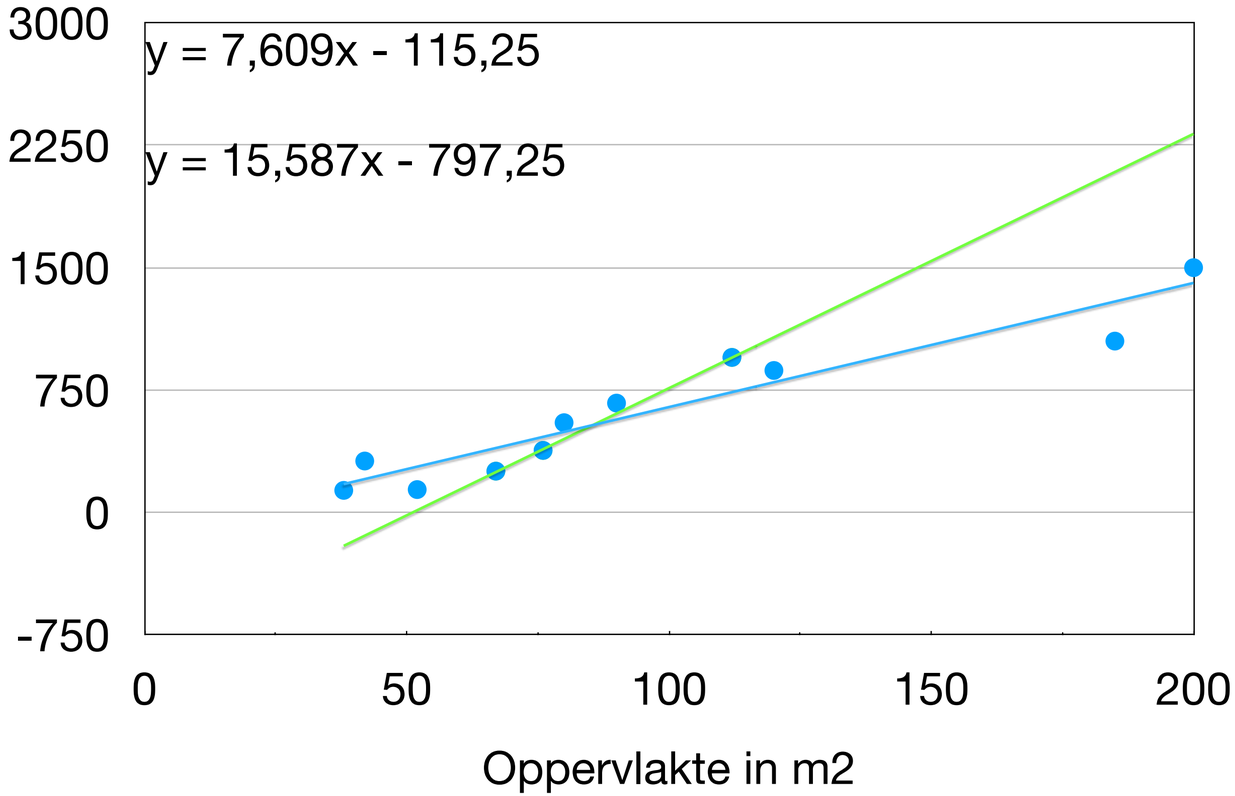
- Het doel is voorspellingen te maken voor data die wij nog niet hebben gezien; dat will zeggen, data die niet voor het bepalen van de parameters is gebruikt.
- Om te bepalen hoe nauwkeurig de voorspellingen zijn die wij maken kunnen wij weer de loss functie gebruiken.
- Maar hiervoor kunnen wij niet dezelfde data gebruiken die wij voor het bepalen van de parameters hebben gebruikt. Dat zou geen goed beeld geven van hoe goed het model generaliseert.

Machine Learning

Een model evalueren

Data Input features Output feature

	Oppervlakte in m2	Verkoopprijs
1	38	135.000
2	42	315.000
3	52	140.000
4	67	253.000
5	76	380.000
6	80	550.000
7	90	670.000
8	112	950.000
9	120	870.000
10	185	1.050.000
11	200	1.500.000

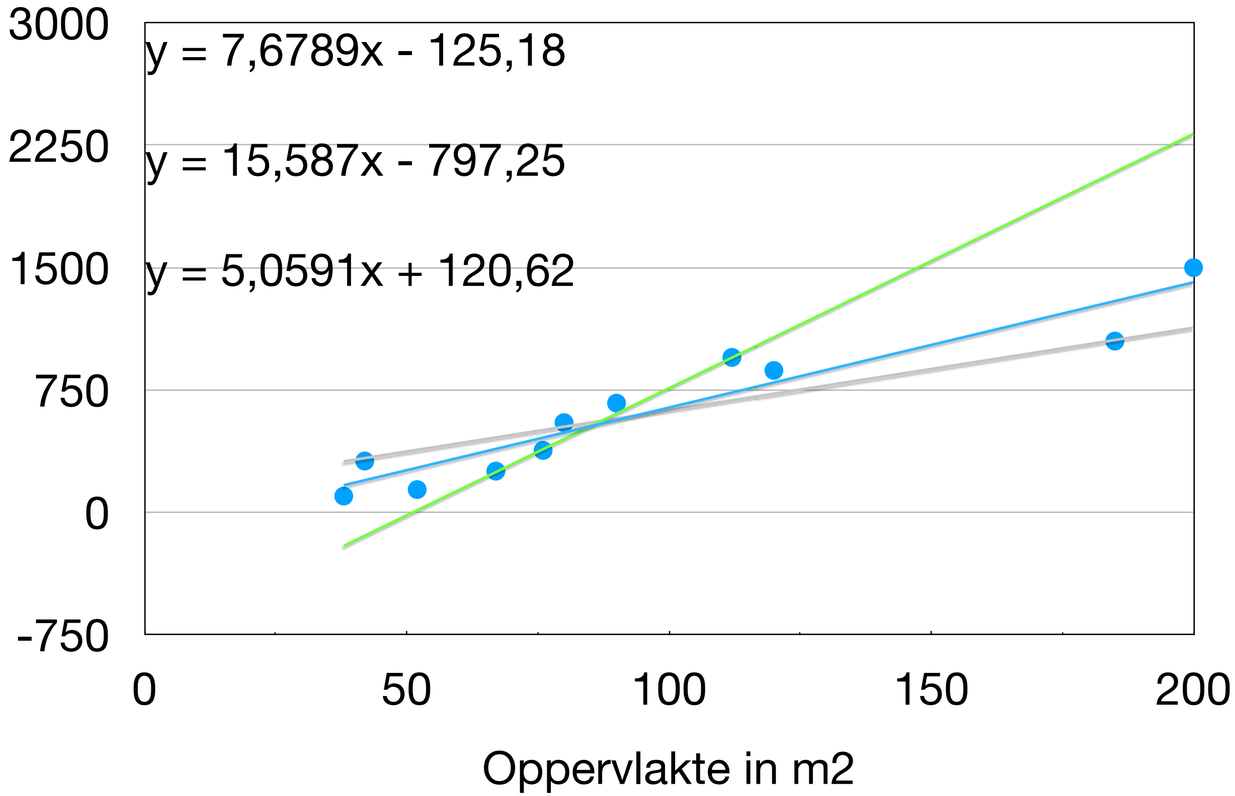


Machine Learning

Een model evalueren

Data Input features Output feature

	Oppervlakte in m2	Verkoopprijs
1	38	135.000
2	42	315.000
3	52	140.000
4	67	253.000
5	76	380.000
6	80	550.000
7	90	670.000
8	112	950.000
9	120	870.000
10	185	1.050.000
11	200	1.500.000



Machine Learning

Training Data and Test Data

Wees zuinig op je data

Wij onderscheiden:

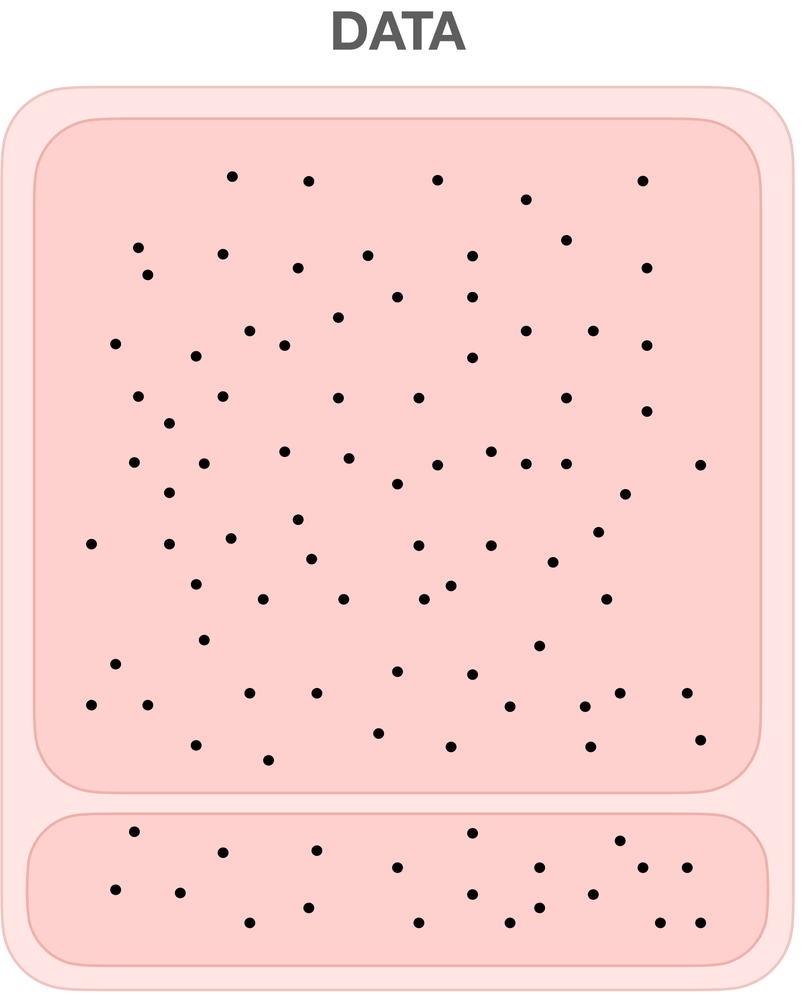
TRAINING DATA

- Deze worden gebruikt om de parameters van het model te bepalen.

TEST DATA

- Deze worden gebruikt om het model te evalueren.
- Dat kan bijvoorbeeld met de MSE (mean squared error):

$$MSE = \frac{\Sigma_1^N (y - \hat{y})^2}{N}$$



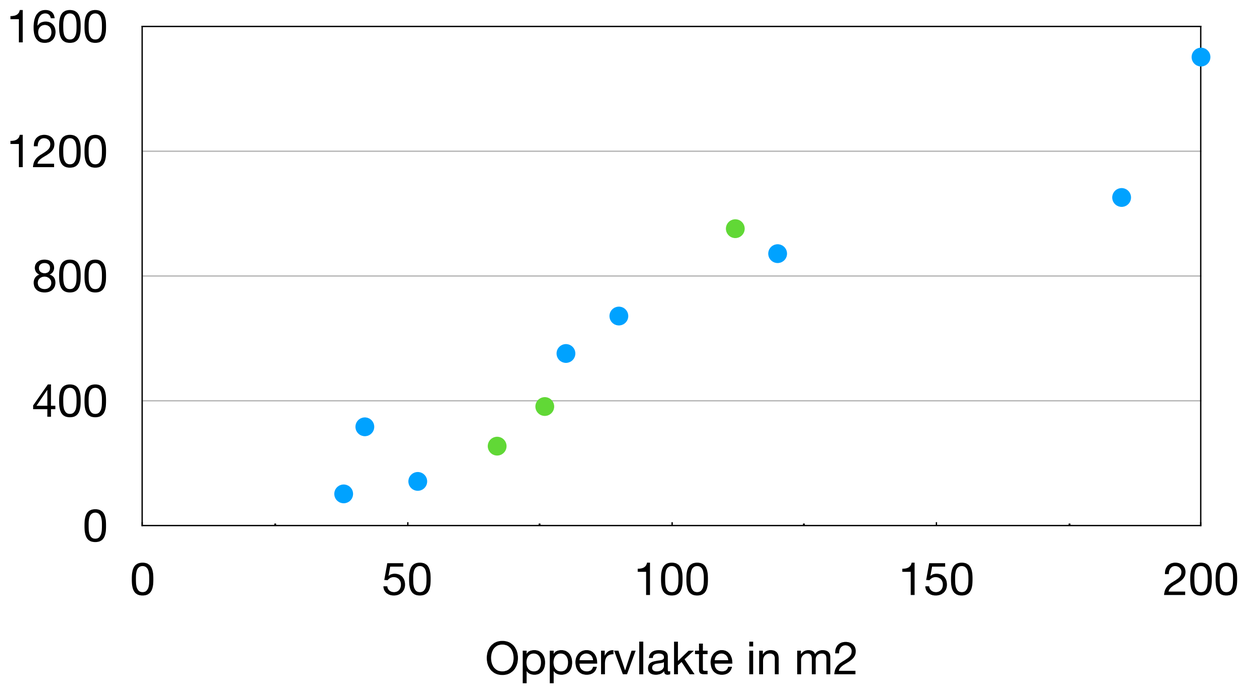
Machine Learning

Een model evalueren

- De datapunten 1, 2, 3, 6, 7, 9, 10, 11 zijn de training data.
- De datapunten 4, 5, 8 zijn de test data.
- We bepalen voor de parameters w = 7,35 en b = -92.
- Het model is $\hat{y} = 7{,}35x - 92$.
- MSE voor de test data is: 16784.
- Dit getal op zichzelf zegt niet veel. Je moet dit in verhouding zien met andere modellen, bijvoorbeeld altijd het gemiddelde voorspellen.

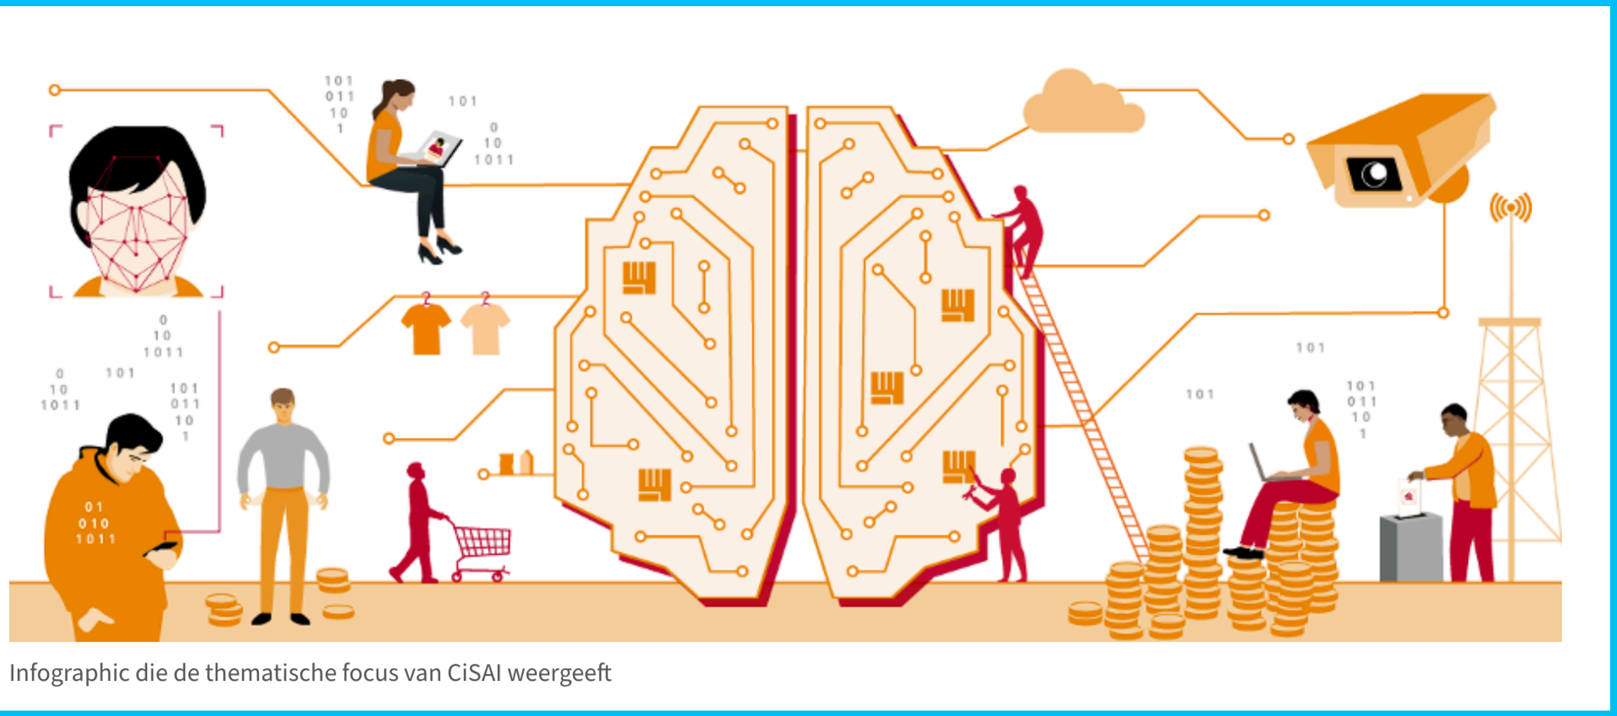
Data **Input features** **Output feature**

	Oppervlakte in m2	Verkoopprijs
1	38	135.000
2	42	315.000
3	52	140.000
4	67	253.000
5	76	380.000
6	80	550.000
7	90	670.000
8	112	950.000
9	120	870.000
10	185	1.050.000
11	200	1.500.000



MACHINE LEARNING DEEL 1

AFRONDING



Infographic die de thematische focus van CiSAI weergeeft

Machine Learning

Leren om te voorspellen

- Het doel is het maken van voorspellingen (weer, diagnose, stemherkenning).
- Hiervoor hebben wij een theorie nodig (**Model**). Dit is voor ML een wiskundige functie met een aantal **parameters** die moeten worden bepaald.
- Wij bepalen welk type functie (model) wordt gefit op de data, i.e. van welke functie wij de parameters moeten bepalen.
- ML gaat over het ontwikkelen van algoritmen die op basis van data de optimale setting voor de parameters bepalen.
- Hiervoor moet het algoritme een optimalisering probleem oplossen: het zoekt de parameters waarvoor de **loss functie** minimaal wordt.
- Een goed model = goede (correcte) voorspellingen, i.e. goede performance op de test data.

Hoorcollege 2

Leerdoel vandaag

Wat kun je aan het eind van de les?

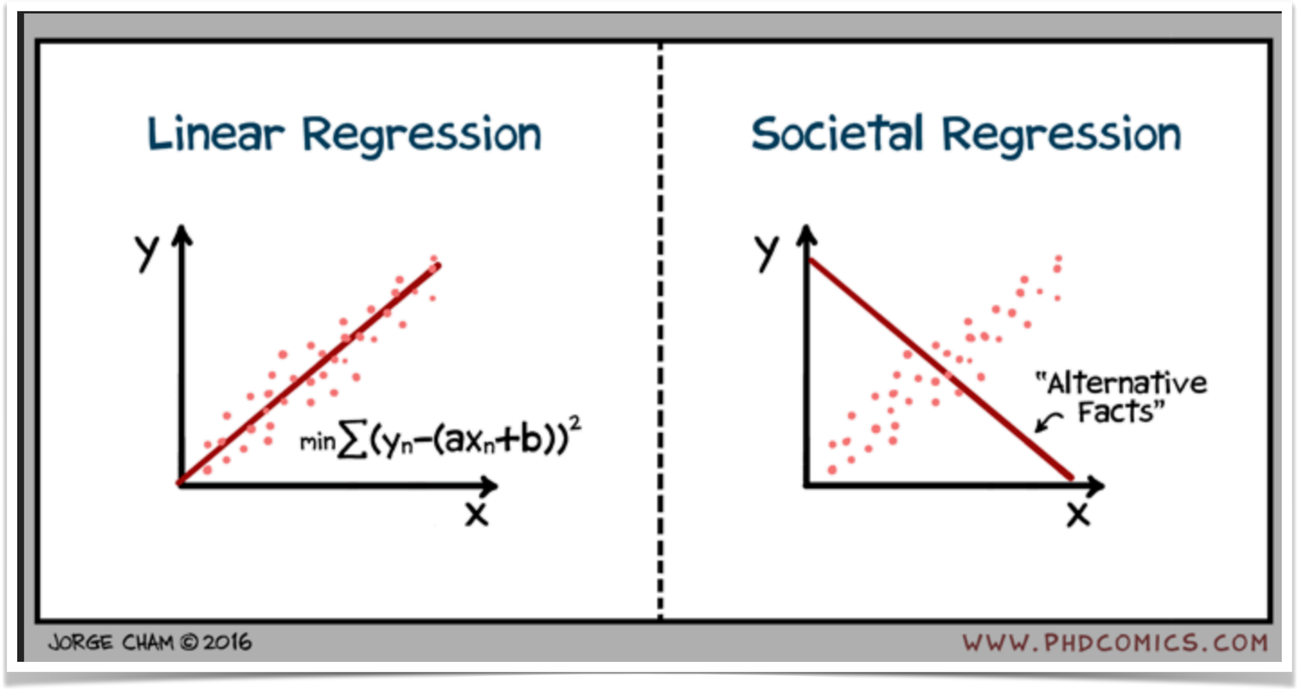
1. Uitleggen wat lineaire regressie is en hoe het werkt.
2. Lineaire regressie op een gegeven dataset toepassen.
3. Uitleggen wat privacy is en welke functie privacy heeft.
4. Evalueren hoe bepaalde AI praktijken of applicaties privacy beperken en een positie betrekken tot het gebruik van deze praktijken/applicaties.
5. Positieve en negatieve vrijheid onderscheiden en herkennen wanneer deze begrippen van toepassing zijn

Sleutelbegrippen

- ➡ Lineaire regressie
- ➡ Squared error loss function
- ➡ Partial derivative
- ➡ Privacy
- ➡ Positieve/negatieve vrijheid

Huiswerk voor de werkgroep (2h)

- Maak de oefenopgaven voor partiële afgeleide. (Inleveren)
- Lees de uitleg voor lineaire regressie en bekijk hoe de parameters algebraïsch kunnen worden bepaald.
- Maak de oefenopgaven over lineaire regressie. (Inleveren)




— BREAK —